Taller de `syscalls`

Departamento de Computación, FCEyN,
Universidad de Buenos Aires, Buenos Aires, Argentina

22 de Marzo de 2016 - 1c2016

Menú

Ahora veremos[1]:

- Syscalls, detrás de las risas
- Herramienta `strace`
- Syscall `ptrace`
- Taller

[1] Algunos ejemplos de este taller NO son compatibles con 64bits

Syscalls en linux - Ejemplo

tinyhello.asm

```
section .data
hello: db 'Hola SO!',10
hello_len: equ $-hello

section .text
global _start
_start:
  mov eax, 4 ; syscall write
  mov ebx, 1 ; stdout
  mov ecx, hello ; mensaje
  mov edx, hello_len
  int 0x80

  mov eax, 1 ; syscall exit
  mov ebx, 0 ;
  int 0x80
```

Syscalls en linux (x86_64) - Ejemplo

tinyhello_64.asm

```
section .data
hello: db 'Hola SO!',10
hello_len: equ $-hello

section .text
global _start
_start:
  mov rax, 1 ; syscall write
  mov rdi, 1 ; stdout
  mov rsi, hello ; mensaje
  mov rdx, hello_len
  syscall

  mov rax, 60 ; syscall exit
  mov rdi,  0 ;
  syscall
```

¿ Qué sucede por lo bajo?

Kernel

```
call syscall_table[__NR_ia32_write]
```

- La magia est en unistd.h
- Provee acceso a la API del kernel
- Estándard Portable Operating System Interface POSIX.1

strace

`strace` es una herramienta que nos permite generar una traza legible de las llamadas al sistema usadas por un programa dado.

Ejemplo strace

```
$ strace -q ./tinyhello > /dev/null
execve("./tinyhello", ["./tinyhello"], [/* 51 vars */]) = 0
write(1, "Hola SO!\n", 9)                        = 9
_exit(0)                                         = ?
```

- `execve` convierte el proceso en una instancia nueva de `./tinyhello` y devuelve 0 indicando que no hubo error.
- `write` escribe en pantalla el mensaje y devuelve la cantidad de caracteres escritos ($= 9$).
- `exit` termina la ejecución y no devuelve ningún valor.

Complicando las cosas: Hello en C

Mismo ejemplo pero en C.

hello.c

```
#include <unistd.h>

int main(int argc, char* argv[]) {
  write(1,"Hola SO!\n",10);
  return 0;
}
```

Compilado estáticamente:

compilación de hello.c

```
gcc -static -o hello hello.c
```

strace en C

strace de un programa en C, ejecutado desde la tty2

```
$ strace -q ./hello
execve("./hello", ["./hello"], [/* 17 vars */]) = 0
uname({sys="Linux", node="nombrehost", ...}) = 0
brk(0)                                  = 0x831f000
brk(0x831fcb0)                          = 0x831fcb0
set_thread_area({entry_number:-1 -> 6, base_addr:0x831f830...}) = 0
brk(0x8340cb0)                          = 0x8340cb0
brk(0x8341000)                          = 0x8341000
write(1, "Hola SO!\n", 9)               = 9
exit_group(0)                           = ?
```

¿Qué es todo esto?

strace - salida en pantalla

La que hace *lo que queremos*

strace ./hello - salida en pantalla

```
write(1, "Hola SO!\n", 9)                    = 9
```

- `write` escribe el mensaje *Hola SO!* en la salida indicada.
- En este caso, el valor 1 es la salida standard.
- Devuelve el valor de cuantos caracteres se escribieron en la salida.

Más syscalls - memoria

Llamadas referentes al manejo de memoria.

strace ./hello - memoria

```
brk(0)                                  = 0x831f000
brk(0x831fcb0)                          = 0x831fcb0
brk(0x8340cb0)                          = 0x8340cb0
brk(0x8341000)                          = 0x8341000
```

- `brk` y `sbrk` modifican el tamaño de la memoria de datos del proceso. `malloc`/`free` usan estas syscalls para agrandar o achicar la memoria usada del proceso. (`malloc` no es una syscall y ofrece otra funcionalidad que `brk`)
- Otras comunes suelen ser `mmap` y textttmmap2 asignan un archivo o dispositivo a una región de memoria. En el caso de `MAP_ANONYMOUS` no se mapea ningún archivo, sólo se crea una porción de memoria disponible para el programa. Para regiones de memoria grandes, `malloc` usa esta syscall.

Más syscalls - otros

strace ./hello - otros

```
execve("./hello", ["./hello"], [/* 17 vars */]) = 0
uname({sys="Linux", node="nombrehost", ...}) = 0
set_thread_area({entry_number:-1 -> 6, base_addr:0x831f830...}) = 0
exit_group(0)                                   = ?
```

- `execve` Cambia el código del programa actual del proceso por el del programa que está pasado por parámetro.
- `uname` devuelve información del sistema donde se está corriendo (nombre del host, versión del kernel, etc).
- `set_thread_area` registra una porción de memoria como memoria local del (único) thread[2] que está corriendo.
- `exit_group` termina el proceso (y todos sus threads).

[2] Threads se verá más adelante

Syscalls - Hello world dinámico

Compilamos el mismo fuente `hello.c` con bibliotecas dinámicas.
Corremos `strace` sobre este programa y encontramos aún más syscalls:

strace ./hello

```
...
access("/etc/ld.so.nohwcap", F_OK)      = -1 ENOENT (No such file or ...)
mmap2(NULL, 8192, PROT_READ|PROT_WRITE,
      MAP_PRIVATE|MAP_ANONYMOUS, -1, 0) = 0xb8017000
access("/etc/ld.so.preload", R_OK)      = -1 ENOENT (No such file or ...)
open("/etc/ld.so.cache", O_RDONLY)      = 3
fstat64(3, {st_mode=S_IFREG|0644, st_size=89953, ...}) = 0
mmap2(NULL, 89953, PROT_READ, MAP_PRIVATE, 3, 0) = 0xb8001000
close(3)                                = 0
...
```

- La secuencia `open`, `fstat`, `mmap2` y `close` mapean el archivo `/etc/ld.so.cache` a una dirección de memoria (`0xb8001000`).

Muchas syscalls para un Hello world

Recordemos nuestro código del programa:

hello.c

```
#include <unistd.h>

int main(int argc, char* argv[]) {
  write(1,"Hola SO!\n",9);
  return 0;
}
```

- El punto de entrada que usa el linker (`ld`) es `_start`.
- El punto de entrada de un programa en C es `main`.
- `gcc` usa `ld` como linker y mantiene su punto de entrada por defecto.
- ¿Qué hay en el medio? ¿Alguna idea?

Muchas syscalls para un Hello world (cont.)

hello.c desensamblado

```
Disassembly of section .text:
08048130 <_start>:
 8048130:  31 ed              xor    ebp,ebp
 8048132:  5e                 pop    esi
 8048133:  89 e1              mov    ecx,esp
 8048135:  83 e4 f0           and    esp,0xfffffff0
 8048138:  50                 push   eax
 8048139:  54                 push   esp
 804813a:  52                 push   edx
 804813b:  68 70 88 04 08     push   0x8048870
 8048140:  68 b0 88 04 08     push   0x80488b0
 8048145:  51                 push   ecx
 8048146:  56                 push   esi
 8048147:  68 f0 81 04 08     push   0x80481f0
 804814c:  e8 cf 00 00 00     call   8048220 <__libc_start_main>
 8048151:  f4                 hlt
```

¡La libc!

libc

Código libc

libc: función __libc_start_main

```
STATIC int
LIBC_START_MAIN (int (*main) (int, char **, char ** MAIN_AUXVEC_DECL),
 int argc, char *__unbounded *__unbounded ubp_av,
#ifdef LIBC_START_MAIN_AUXVEC_ARG
 ElfW(auxv_t) *__unbounded auxvec,
#endif
 __typeof (main) init,
 void (*fini) (void),
 void (*rtld_fini) (void), void *__unbounded stack_end)
{
  ...
    /* Nothing fancy, just call the function.  */
  result = main (argc, argv, __environ MAIN_AUXVEC_PARAM);
  exit (result);
}
```

Ejemplos de "la vida real"

Demo `strace`

- `date`
- `cat`
- `time date`

Syscalls en linux - parando la pelota

- EAX (o RAX) y el rol de `unistd.h` (POSIX)

Syscalls en linux - parando la pelota

- EAX (o RAX) y el rol de `unistd.h` (POSIX)
- Assembler y la grasa militante de la libc

Syscalls en linux - parando la pelota

- EAX (o RAX) y el rol de `unistd.h` (POSIX)
- Assembler y la grasa militante de la libc
- Herramienta `strace`

Syscalls en linux - parando la pelota

- EAX (o RAX) y el rol de `unistd.h` (POSIX)
- Assembler y la grasa militante de la libc
- Herramienta `strace`
- ¿Cómo funciona `strace`?

Syscalls en linux - parando la pelota

- EAX (o RAX) y el rol de `unistd.h` (POSIX)
- Assembler y la grasa militante de la libc
- Herramienta `strace`
- ¿Cómo funciona `strace`?
- `strace strace`

Detrás de escena: ptrace

ptrace es una syscall más. Antes que nada, man es nuestro amigo.

man 2 ptrace

```
NAME
       ptrace - process trace

SYNOPSIS
       #include <sys/ptrace.h>

       long ptrace(enum __ptrace_request request, pid_t pid,
                   void *addr, void *data);
```

Permite observar y controlar un proceso hijo. En particular permite obtener una traza del proceso, desde el punto de vista del sistema operativo.
Al llamar a la syscall ptrace desde un proceso padre el sistema operativo le "avisa" cada vez que el proceso hijo hace una syscall o recibe una señal.

Usando ptrace

Vamos a usar ptrace para monitorear un proceso.

prototipo de ptrace

```
long ptrace(enum __ptrace_request request, pid_t pid,
            void *addr, void *data);
```

request puede ser alguno de estos:

- PTRACE_TRACEME, PTRACE_ATTACH, PTRACE_DETACH
- PTRACE_KILL, PTRACE_CONT
- PTRACE_SYSCALL, PTRACE_SINGLESTEP
- PTRACE_PEEKDATA, PTRACE_POKEDATA
- PTRACE_PEEKUSER, PTRACE_POKEUSER
- ...y más[3]

[3] Vea man 2 ptrace

Usando ptrace (cont.)

Situación:

- Proceso padre
- Proceso hijo que queremos monitorear

Inicialización, dos alternativas:

1. El proceso padre se engancha al proceso hijo con la llamada `ptrace(PTRACE_ATTACH, pid_child)`.
   Esto permite engancharse a un proceso que ya está corriendo (si se tienen permisos suficientes).
2. El proceso hijo solicita ser monitoreado haciendo una llamada a `ptrace(PTRACE_TRACEME)`.

Finalización:

- Con la llamada `ptrace(PTRACE_DETACH, pid_child)` se deja de monitorear.

Usando ptrace (cont.)

`ptrace` permite monitorear tres tipos de eventos:

- Señales: Avisa cuando el proceso hijo recibe una señal.
- Syscalls: Avisa cada vez que el proceso hijo entra o sale de la llamada a una syscall.
- Instrucciones: Avisa cada vez que el proceso hijo ejecuta **una** instrucción.

Cada vez que se genera un evento el proceso hijo se detiene. Para reanudarlo hasta el siguiente evento el proceso padre puede:

- llamar a `ptrace(PTRACE_CONT)` para reanudar el hijo hasta la siguiente señal recibida.
- llamar a `ptrace(PTRACE_SYSCALL)` para reanudar el hijo hasta la siguiente señal recibida o syscall ejecutada.
- llamar a `ptrace(PTRACE_SINGLESTEP)` para reanudar el hijo sólo por una instrucción.

Esquema de uso (simplificado)

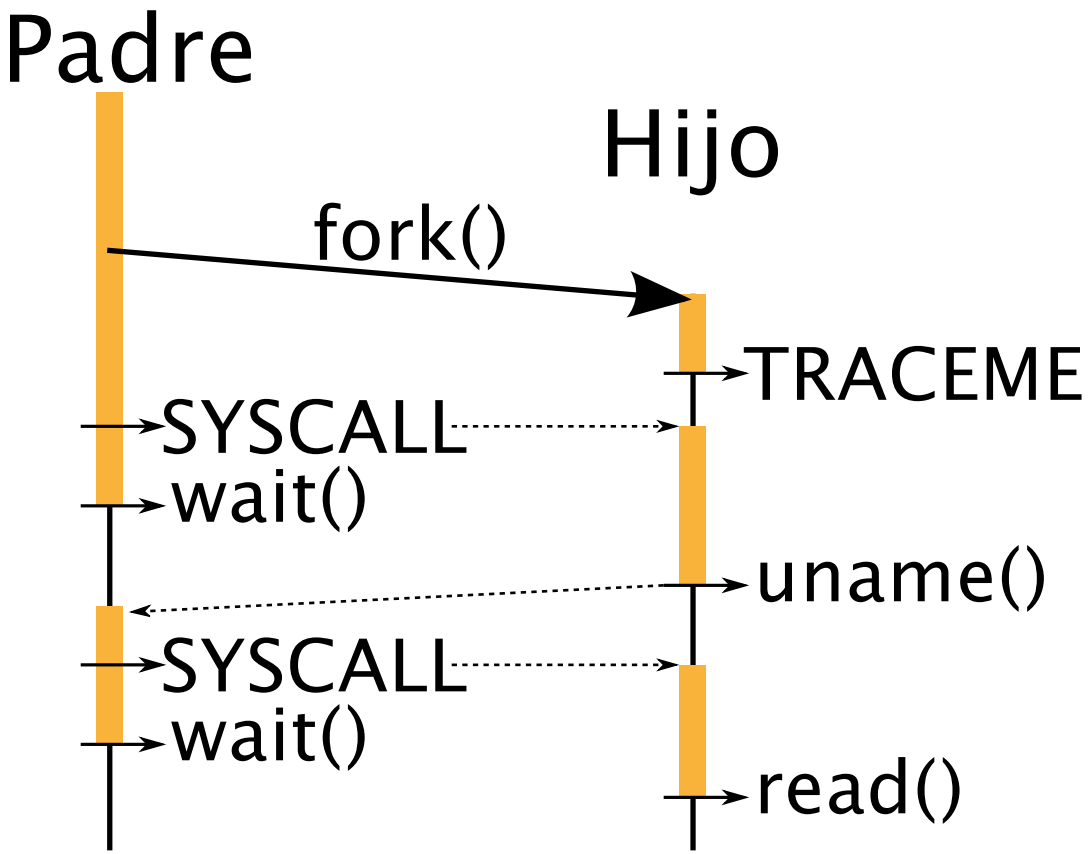

Ejemplo **simplificado** del mecanismo de bloqueo de ptrace.

El hijo se detiene cada vez que llama a una syscall. El padre lo reanuda con una llamada a `ptrace(PTRACE_SYSCALL)`.

Esquema de uso

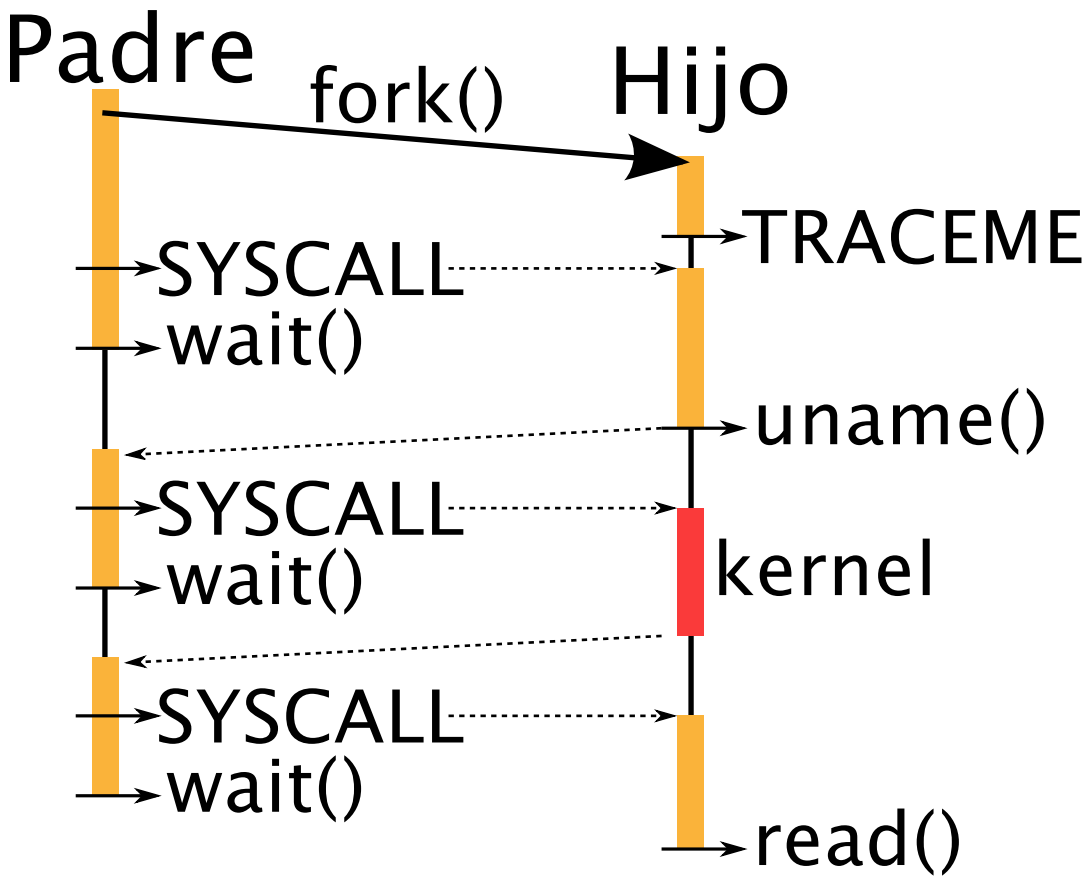

En realidad, el padre recibe dos eventos, al entrar y salir de la syscall.

Usando ptrace (cont.)

Esquema de comunicación:

1. Se inicializa el mecanismo de `ptrace` (`PTRACE_TRACEME` o `PTRACE_ATTACH`).
2. padre: Llama a `wait`: espera el próximo evento del hijo.
3. hijo: Ejecuta normalmente hasta que se genere un evento (recibir una señal, hacer una syscall o ejecutar una instrucción).
4. hijo: Se genera el evento y el proceso se detiene.
5. padre: Vuelve de la syscall `wait`.
6. padre: Puede inspecionar y modificar el estado del hijo: registros, memoria, etc.
7. padre: Reanuda el proceso hijo con `PTRACE_CONT`, `PTRACE_SYSCALL` o `PTRACE_SINGLESTEP` y vuelve a 2.
8. padre: o bien: Termina el proceso con `PTRACE_KILL` o lo libera con `PTRACE_DETACH`.

Usando ptrace: launch

Veamos un programa launch para poner a ejecutar otro programa

launch.c - main()

```
/* Fork en dos procesos */
child = fork();
if (child == -1) { perror("ERROR fork"); return 1; }
if (child == 0) {
  /* S'olo se ejecuta en el Hijo */
  execvp(argv[1], argv+1);
  /* Si vuelve de exec() hubo un error */
  perror("ERROR child exec(...)"); exit(1);
} else {
  /* S'olo se ejecuta en el Padre */
  while(1) {
    if (wait(&status) < 0) { perror("waitpid"); break; }
    if (WIFEXITED(status)) break; /* Proceso terminado */
  }
}
```

Usando ptrace: launch + ptrace

launch.c + ptrace

```
child = fork();
if (child == -1) { perror("ERROR fork"); return 1; }
if (child == 0) {
  /* Sólo se ejecuta en el Hijo */
  if (ptrace(PTRACE_TRACEME, 0, NULL, NULL)) {
    perror("ERROR child ptrace(PTRACE_TRACEME, ...)"); exit(1);
  }
  execvp(argv[1], argv+1);
  /* Si vuelve de exec() hubo un error */
  perror("ERROR child exec(...)"); exit(1);
} else {
  /* Sólo se ejecuta en el Padre */
  while(1) {
    if (wait(&status) < 0) { perror("wait"); break; }
    if (WIFEXITED(status)) break; /* Proceso terminado */
    ptrace(PTRACE_SYSCALL, child, NULL, NULL); /* continúa */
  }
  ptrace(PTRACE_DETACH, child, NULL, NULL);/*Liberamos al hijo*/
```

Usando ptrace - Estado del proceso hijo

`ptrace` permite acceder (leer o escribir) la memoria del proceso hijo:

- `PTRACE_PEEKDATA` y `PTRACE_POKEDATA`
  Se puede leer (`PEEK`) o escribir (`POKE`) cualquier dirección de memoria en el proceso hijo.
- `PTRACE_PEEKUSER`, `PTRACE_POKEUSER` Se puede leer o escribir la memoria de usuario que el sistema guarda al iniciar la syscall: registros y estado del proceso.

Ejemplos

Obtenemos el número de syscall llamada:

```
int sysno = ptrace(PTRACE_PEEKUSER, child, 4*ORIG_EAX, NULL);
```

Leemos la dirección `addr` (direción del proceso hijo):

```
unsigned int valor = ptrace(PTRACE_PEEKDATA, child, addr, NULL);
```

Escribimos otro valor en la direccion `addr`:

```
ptrace(PTRACE_POKEDATA, child, addr, valor+1);
```

Esquema de uso - obteniendo datos

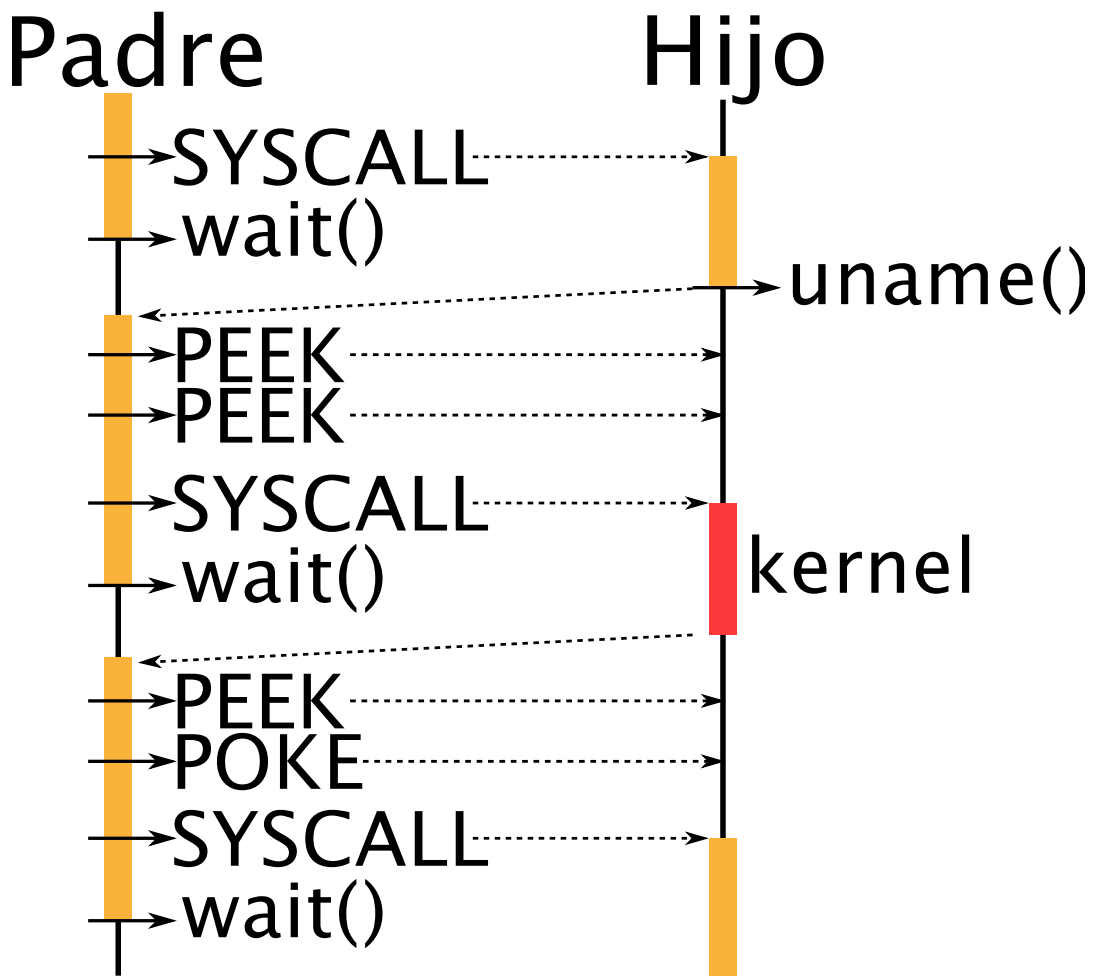

Mientras el proceso hijo está detenido, se pueden obtener y modificar datos con `PTRACE_PEEKDATA`, `PTRACE_POKEDATA`, `PTRACE_PEEKUSER` y `PTRACE_POKEUSER`.

Esquema de uso - Debugger

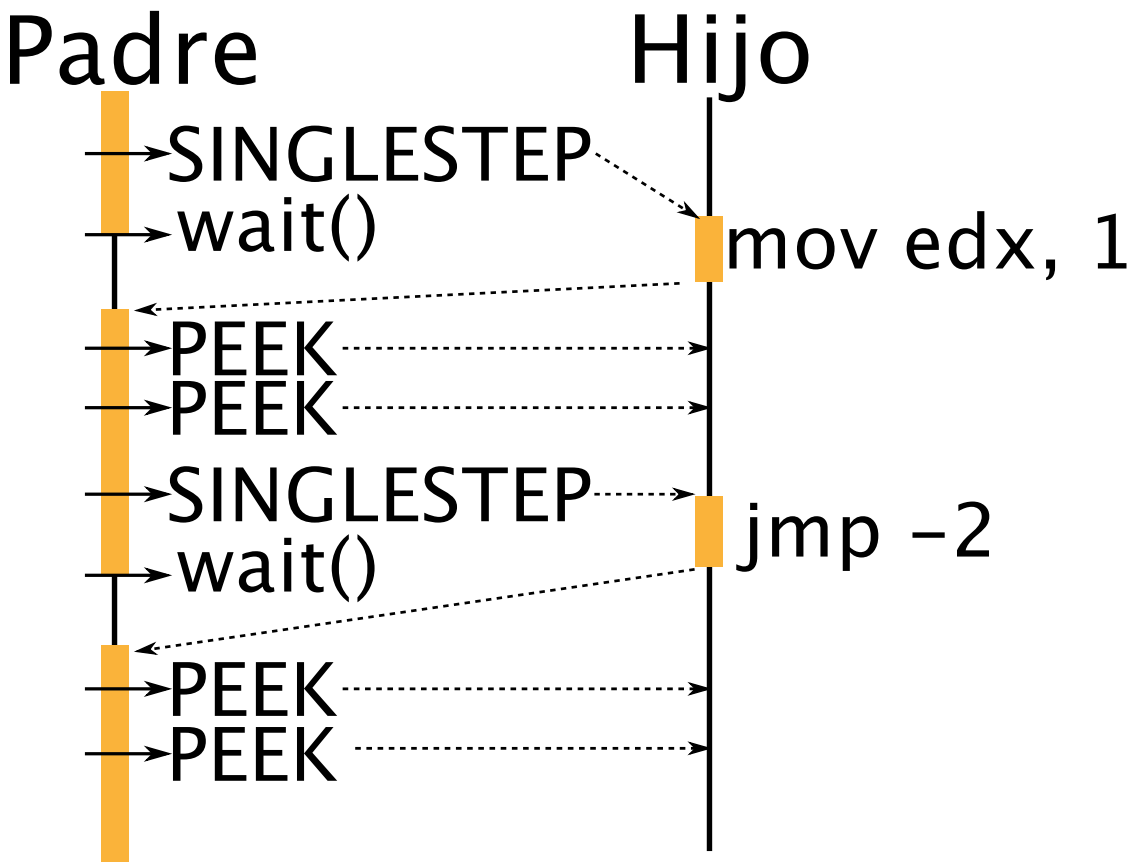

Un debugger puede usar `PTRACE_SINGLESTEP` para ejecutar paso a paso cada instrucción.